


SƠ LƯỢC VỀ KHOA HỌC DỮ LIỆU

Khoa học Dữ liệu - Data science



Khoa học về phân tích dữ liệu

“In God we trust.
All others bring
data”.

“Ta tin Thượng đế.
Ngoài ra, là dữ
liệu”.


W.E. Deming



“We cannot solve problems
by using the same kind of
thinking we used when we
created them”

Ta không thể giải quyết các
vấn đề với chính cách nghĩ ta
đã dùng khi đặt vấn đề

Albert Einstein



Kết hợp toán học và tin học là công cụ phân tích dữ liệu lớn


Vai trò của dữ liệu lớn?

Andrew Ng's Analogy

Mô hình tính toán lớn,
e.g., deep learning/AI

Cơ sở hạ tầng tính
toán, nhà nghiên cứu,
môi trường và chính
sách như bộ phóng

Dữ liệu là năng lượng.
Dữ liệu lớn là nguồn
năng lượng khổng lồ



Hiding within huge mounds
of data is knowledge that
could change the our world.


Ẩn trong khối dữ liệu khổng
lồ là kiến thức có thể thay
đổi thế giới của chúng ta.

● Khám phá khoa học dựa vào dữ liệu lớn

Science Paradigms

- Thousand years ago:
science was **empirical**
describing natural phenomena
- Last few hundred years:
theoretical branch
using models, generalizations
- Last few decades:
a **computational** branch
simulating complex phenomena
- Today: **data exploration** (eScience)
unify theory, experiment, and simulation
 - Data captured by instruments
or generated by simulator
 - Processed by software
 - Information/knowledge stored in computer
 - Scientist analyzes database/files
using data management and statistics

$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{4\pi G \rho}{3} - K \frac{c^2}{a^2}$$




← Thực nghiệm

← Lý thuyết

← Tính toán và mô phỏng

← Khám phá dữ liệu



Data-intensive Scientific Discovery

Leo Breiman là nhà thống kê/ học máy lỗi lạc của Berkeley, tác giả decision trees và random forests, viết về văn hoá trong mô hình suy diễn

Statistical Science
2001, Vol. 16, No. 3, 199-231

Statistical Modeling: The Two Cultures

Leo Breiman

Abstract. There are two cultures in the use of statistical modeling to reach conclusions from data. One assumes that the data are generated by a given stochastic data model. The other uses algorithmic models and treats the data mechanism as unknown. The statistical community has been committed to the almost exclusive use of data models. This commitment has led to irrelevant theory, questionable conclusions, and has kept statisticians from working on a large range of interesting current problems. Algorithmic modeling, both in theory and practice, has developed rapidly in fields outside statistics. It can be used both on large complex data sets and as a more accurate and informative alternative to data modeling on smaller data sets. If our goal as a field is to use data to solve problems, then we need to move away from exclusive dependence on data models and adopt a more diverse set of tools.

Có hai mục tiêu suy diễn/ học thống kê

- dự báo (to predict)
- thiết lập quy luật, hiểu biết về mối quan hệ (to infer/ understand)

Prediction

Mọi phương pháp dự báo đều bắt đầu từ dữ liệu X để ước lượng Y

$$X \longrightarrow \boxed{METHOD} \longrightarrow Y$$

Ví dụ: dữ liệu X về dung lượng giao thông của các địa điểm
 Y là một giá trị nhị phân để dự báo đường có bị tắc hay không

Giả dụ: X và Y được liên hệ với nhau bởi một đại lượng chân lý nào đó kết nối X và Y , ta tạm gọi là θ

$$X \longleftrightarrow \theta \longleftrightarrow Y$$

Chúng ta không bao giờ biết được chính xác θ (chỉ có Trời mới biết!)
Breiman nói đến hai cách tiếp cận khác nhau trong bài toán prediction

- Algorithmic Modeling
- Data Modeling

ALGORITHMIC MODELING không quan tâm lắm đến bản chất sự liên hệ giữa dung lượng giao thông với sự tắc đường mô tả bởi θ , nó chỉ muốn tìm ra một hàm dự báo $y = f(x)$

$$\{X, Y\} \implies \boxed{\text{ALGORITHM MODEL}} \implies f$$

Chạy thuật toán *blackbox* như *decision tree, kernel machine, neural net* để học f , với mục tiêu sao cho $f(X)$ càng gần với Y càng tốt

Vậy f có liên quan gì đến θ ?

DATA MODELING tìm cách thiết lập một chất keo toán học kết dính X với Y , thông qua một mô hình xác suất liên hệ biến ngẫu nhiên X và biến ngẫu nhiên Y

$$\{X, Y\} \longrightarrow \boxed{\text{DATA MODEL}} \longrightarrow \mathbb{P}(Y|X, \hat{\theta})$$

$\hat{\theta}$ là một ước lượng của chân lý θ , thông qua đó ta thiết lập được liên hệ giữa Y và X thông qua phân bố điều kiện của Y khi cho X .

Phân bố này cho ta một hàm số dự báo gọi là optimal Bayes classifier

$$f(x) = 1 \text{ if } \mathbb{P}(Y|X, \hat{\theta}) > 1/2, \quad 0 \text{ otherwise}$$

Lý thuyết học thống kê đối với bài toán phân lớp cho biết, hai phương pháp chỉ là hai mặt của một vấn đề:



- DATA MODELING is good only if $\hat{\theta}$ approximates well the true θ
- ALGORITHMIC MODELING is good only if the outcome f approximates well the optimal Bayes classifier đối với true θ
- There is no silver bullet!
- Distinction between data model and algorithm model may disappear as both become richer, e.g.:
 - ▶ Bayesian nonparametric data model may be described algorithmically
 - ▶ Randomized algorithm entails a stochastic process (e.g., Markov chain)

Hai văn hoá

Machine Learning

- chú trọng đến **mô hình thuật toán** nhiều hơn **mô hình dữ liệu** (đặc biệt cho prediction/ supervised learning)
- cộng đồng học máy rất năng động: học một công cụ toán/ thống kê, rebranding, và sở hữu nó rất nhanh; chạy theo mốt với tốc độ chóng mặt

Hai văn hoá

Machine Learning

- chú trọng đến **mô hình thuật toán** nhiều hơn **mô hình dữ liệu** (đặc biệt cho prediction/ supervised learning)
- cộng đồng học máy rất năng động: học một công cụ toán/ thống kê, rebranding, và sở hữu nó rất nhanh; chạy theo một với tốc độ chóng mặt

Statistics

Statistics sâu về toán học và có bề dày về các lý thuyết suy diễn

- prediction, parameter estimation, hypothesis test
- không chỉ quan tâm đến kết quả ước lượng, mà cả mức độ bất định của ước lượng (confidence intervals, credible intervals,...)

Machine Learning học hỏi nhiều từ nền tảng toán thống kê và mô hình dữ liệu. Ngược lại, sự trưởng thành của Machine Learning giúp các nhà thống kê bùng nổ, đánh giá đúng hơn vai trò của thuật toán và computing architecture.

INPUT:

The William Randolph Hearst Foundation will give \$1.25 million to Lincoln Center, Metropolitan Opera Co., New York Philharmonic and Juilliard School. "Our board felt that we had a real opportunity to make a mark on the future of the performing arts with these grants an act every bit as important as our traditional areas of support in health, medical research, education and the social services," Hearst Foundation President Randolph A. Hearst said Monday in announcing the grants. Lincoln Center's share will be \$200,000 for its new building, which will house young artists and provide new public facilities. The Metropolitan Opera Co. and New York Philharmonic will receive \$400,000 each. The Juilliard School, where music and the performing arts are taught, will get \$250,000. The Hearst Foundation, a leading supporter of the Lincoln Center Consolidated Corporate Fund, will make its usual annual \$100,000 donation, too.

OUTPUT:

"Arts"	"Budgets"	"Children"	"Education"
NEW	MILLION	CHILDREN	SCHOOL
FILM	TAX	WOMEN	STUDENTS
SHOW	PROGRAM	PEOPLE	SCHOOLS
MUSIC	BUDGET	CHILD	EDUCATION
MOVIE	BILLION	YEARS	TEACHERS
PLAY	FEDERAL	FAMILIES	HIGH
MUSICAL	YEAR	WORK	PUBLIC
BEST	SPENDING	PARENTS	TEACHER
ACTOR	NEW	SAYS	BENNETT
FIRST	STATE	FAMILY	MANIGAT
YORK	PLAN	WELFARE	NAMPHY
OPERA	MONEY	MEN	STATE
THEATER	PROGRAMS	PERCENT	PRESIDENT
ACTRESS	GOVERNMENT	CARE	ELEMENTARY
LOVE	CONGRESS	LIFE	HAITI

Dữ liệu thô:

$x =$

The William Randolph Hearst Foundation will give \$1.25 million to Lincoln Center, Metropolitan Opera Co., New York Philharmonic and Juilliard School. “Our board felt that we had a real opportunity to make a mark on the future of the performing arts with these grants and we put every bit as important as our traditional areas of support in health, medical research, education and the social services,” Hearst Foundation President Randolph A. Hearst said Monday announcing the grants. Lincoln Center’s share will be \$200,000 for its new building, which will house young artists and provide new public facilities. The Metropolitan Opera Co. and New York Philharmonic will receive \$400,000 each. The Juilliard School, where music and the performing arts are taught, will get \$250,000. The Hearst Foundation, a leading supporter of the Lincoln Center Consolidated Corporate Fund, will make its usual annual \$100,000 donation, too.

Chân lý:

$\theta =$

“Arts”	“Budgets”	“Children”	“Education”
NEW	MILLION	CHILDREN	SCHOOL
FILM	TAX	WOMEN	STUDENTS
SHOW	PROGRAM	PEOPLE	SCHOOLS
MUSIC	BUDGET	CHILD	EDUCATION
MOVIE	BILLION	YEARS	TEACHERS
PLAY	FEDERAL	FAMILIES	HIGH
MUSICAL	YEAR	WORK	PUBLIC
BEST	SPENDING	PARENTS	TEACHER
ACTOR	NEW	SAYS	BENNETT
FIRST	STATE	FAMILY	MANIGAT
YORK	PLAN	WELFARE	NAMPHY
OPERA	MONEY	MEN	STATE
THEATER	PROGRAMS	PERCENT	PRESIDENT
ACTRESS	GOVERNMENT	CARE	ELEMENTARY
LOVE	CONGRESS	LIFE	HAITI

Dữ liệu thô:

$x =$

The William Randolph Hearst Foundation will give \$1.25 million to Lincoln Center, Metropolitan Opera Co., New York Philharmonic and Juilliard School. “Our board felt that we had a real opportunity to make a mark on the future of the performing arts with these grants an act every bit as important as our traditional areas of support in health, medical research, education and the social services,” Hearst Foundation President Randolph A. Hearst said Monday in announcing the grants. Lincoln Center’s share will be \$200,000 for its new building, which will house young artists and provide new public facilities. The Metropolitan Opera Co. and New York Philharmonic will receive \$400,000 each. The Juilliard School, where music and the performing arts are taught, will get \$250,000. The Hearst Foundation, a leading supporter of the Lincoln Center Consolidated Corporate Fund, will make its usual annual \$100,000 donation, too.

Chân lý:

$\theta =$


“Arts”	“Budgets”	“Children”	“Education”
NEW	MILLION	CHILDREN	SCHOOL
FILM	TAX	WOMEN	STUDENTS
SHOW	PROGRAM	PEOPLE	SCHOOLS
MUSIC	BUDGET	CHILD	EDUCATION
MOVIE	BILLION	YEARS	TEACHERS
PLAY	FEDERAL	FAMILIES	HIGH
MUSICAL	YEAR	WORK	PUBLIC
BEST	SPENDING	PARENTS	TEACHER
ACTOR	NEW	SAYS	BENNETT
FIRST	STATE	FAMILY	MANIGAT
YORK	PLAN	WELFARE	NAMPY
OPERA	MONEY	MEN	STATE
THEATER	PROGRAMS	PERCENT	PRESIDENT
ACTRESS	GOVERNMENT	CARE	ELEMENTARY
LOVE	CONGRESS	LIFE	HAITI

Biểu diễn cho mô hình sinh dữ liệu $\mathbb{P}(\mathbf{x}|\boldsymbol{\theta})$

$$\mathbb{P} \left(\mathbf{x} = \begin{array}{|l} \text{The William Randolph Hearst Foundation will give \$1.25 million to Lincoln Center, Metropolitan Opera Co., New York Philharmonic and Juilliard School. "Our board felt that we had a real opportunity to make a mark on the future of the performing arts with these grants an act every bit as important as our traditional areas of support in health, medical research, education and the social services," Hearst Foundation President Randolph A. Hearst said Monday in announcing the grants. Lincoln Center's share will be \$200,000 for its new building, which will house young artists and provide new public facilities. The Metropolitan Opera Co. and New York Philharmonic will receive \$400,000 each. The Juilliard School, where music and the performing arts are taught, will get \$250,000. The Hearst Foundation, a leading supporter of the Lincoln Center Consolidated Corporate Fund, will make its usual annual \$100,000 donation, too.} \end{array} \mid \boldsymbol{\theta} = \begin{array}{|l|l|l|l|} \hline \text{"Arts"} & \text{"Budgets"} & \text{"Children"} & \text{"Education"} \\ \hline \text{NEW} & \text{MILLION} & \text{CHILDREN} & \text{SCHOOL} \\ \text{FILM} & \text{TAX} & \text{WOMEN} & \text{STUDENTS} \\ \text{SHOW} & \text{PROGRAM} & \text{PEOPLE} & \text{SCHOOLS} \\ \text{MUSIC} & \text{BUDGET} & \text{CHILD} & \text{EDUCATION} \\ \text{MOVIE} & \text{BILLION} & \text{YEARS} & \text{TEACHERS} \\ \text{PLAY} & \text{FEDERAL} & \text{FAMILIES} & \text{HIGH} \\ \text{MUSICAL} & \text{YEAR} & \text{WORK} & \text{PUBLIC} \\ \text{BEST} & \text{SPENDING} & \text{PARENTS} & \text{TEACHER} \\ \text{ACTOR} & \text{NEW} & \text{SAYS} & \text{BENNETT} \\ \text{FIRST} & \text{STATE} & \text{FAMILY} & \text{MANGAT} \\ \text{YORK} & \text{PLAN} & \text{WELFARE} & \text{NAMPBY} \\ \text{OPERA} & \text{MONEY} & \text{MEN} & \text{STATE} \\ \text{THEATER} & \text{PROGRAMS} & \text{PERCENT} & \text{PRESIDENT} \\ \text{ACTRESS} & \text{GOVERNMENT} & \text{CARE} & \text{ELEMENTARY} \\ \text{LOVE} & \text{CONGRESS} & \text{LIFE} & \text{HAITI} \\ \hline \end{array} \right)$$

- Cho V là bộ từ điển gồm có d phần tử (từ vựng) được đánh số bằng $V = \{1, \dots, d\}$
 - ▶ với văn bản dài n từ, ta viết $\mathbf{x} = (x_1, \dots, x_n) \in V^n$.
- Giả sử rằng có k chủ đề ẩn khác nhau $\boldsymbol{\theta} = (\theta_1, \dots, \theta_k)$, tương ứng với k phần tử nằm trong đơn hình xác suất

$$\Delta^{d-1} := \{u \in [0, 1]^d \mid u_1 + \dots + u_d = 1\}.$$



Mỗi chủ đề $\theta_i \in \Delta^{d-1}$ tương ứng với một tần suất xuất hiện nhất định của các từ trong V .

- Ví dụ: một chủ đề về “giáo dục” sẽ có nhiều từ với tần suất xuất hiện cao, như “trường”, “lớp”, “học sinh”, “học phí”, v.v.
- Một chủ đề về “đảng” sẽ có những từ khác với tần suất cao, như “nghị quyết”, “quán triệt”, “tiến lên”, “to lớn”, v.v.

Optimization

$$\max_{\theta} \mathbb{P}(\mathbf{x} =$$

The *William Randolph Hearst Foundation* will give **\$1.15 million** to *Lincoln Center*, *Metropolitan Opera*, *New York Philharmonic*, and *Lincoln School*. "The *Hearst* felt that we had a real opportunity to make a mark on the future of the performing arts with these grants as well as every bit as important as our traditional areas of support in health, medical research, education and the social sciences," *Hearst Foundation* President *Bartholdy A. Hearst* said. *Lincoln Center* will receive **\$400,000** for its new building, which will house young artists and provide new artistic facilities. The *Metropolitan Opera* Co. and *New York Philharmonic* will receive **\$400,000** each. The *Lincoln School*, whose music and the performing arts are taught, will get **\$250,000**. The *Hearst Foundation*, a leading supporter of the Lincoln Center Consortium, Corporate Trust, will make its total grant **\$1,000,000**, *Hearst*, Inc.

50 years of Data Science

David Donoho

Sept. 18, 2015
Version 1.00

Abstract

35 ago, John Tukey called for a reformation of academic statistics, he pointed to the existence of an as-yet unrecognized learning from data, or "data analysis". Ten to two hundred and Leo Breiman independently once again urged a reformation beyond the classical domain of theoretical statistics, emphasizing data preparation and presentation rather than statistical inference on prediction rather than inference. Cleveland's "The Art of Data Science" for his envisioned field.

Statistical Modeling: The Two Cultures
Leo Breiman

Abstract: There are two cultures in the use of statistical modeling to learn from data. One assumes that the data are generated by a given stochastic data model. The other uses algorithmic models and treats the data as a black box. The statistical community has been committed to the former culture for a long time. This report, which has led to a new culture, is a review of the latter culture, and has been motivated by the need to learn from data. The report is a review of the latter culture, and has been motivated by the need to learn from data. The report is a review of the latter culture, and has been motivated by the need to learn from data.

So we obtain

$\theta =$

"Arts"	"Budgets"	"Children"	"Education"
NEW	MILLION	CHILDREN	SCHOOL
FILM	TAX	WOMEN	STUDENTS
SHOW	PROGRAM	PEOPLE	SCHOOLS
MUSIC	BUDGET	CHILD	EDUCATION
MOVIE	BILLION	YEARS	TEACHERS
PLAY	FEDERAL	FAMILIES	HIGH
MUSICAL	YEAR	WORK	PUBLIC
BEST	SPENDING	PARENTS	TEACHER
ACTOR	NEW	SAYS	BENNETT
FIRST	STATE	FAMILY	MANIGAT
YORK	PLAN	WELFARE	NAMPHY
OPERA	MONEY	MEN	STATE
THEATER	PROGRAMS	PERCENT	PRESIDENT
ACTRESS	GOVERNMENT	CARE	ELEMENTARY
LOVE	CONGRESS	LIFE	HAITI

Maximum Likelihood Estimation

(Ước lượng bằng cực đại khả dĩ)

Trong thống kê toán có một phương pháp ước lượng rất mạnh và hữu dụng, dựa vào phép lấy cực đại của hàm khả dĩ của Fisher.

Hàm *khả dĩ* (likelihood function) là một hàm số đối với tham số θ của (mật độ) phân bố $p(\mathbf{x}|\theta)$.

Ước lượng cực đại của hàm khả dĩ, viết tắt bằng MLE, khi đã được cho các dữ liệu $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}$ được định nghĩa như sau:

$$\hat{\theta} := \arg \max_{\theta} \sum_{i=1}^m \log p(\mathbf{x}^{(i)}|\theta).$$

Một bảo đảm quan trọng đối với ước lượng MLE cho lớp mô hình chủ đề:

Theorem (Nguyen, 2015)

Với $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_k)$ là ước lượng MLE. Viết $\hat{G} := \text{conv}(\hat{\theta}_1, \dots, \hat{\theta}_k)$. Nếu m và n cùng tiến tới vô cùng, trong đó $\log \log m \leq \log n = o(m)$, ta có

$$d_H(\hat{G}, G) = O_P \left(\frac{\log m}{m} + \frac{\log n}{n} + \frac{\log n}{m} \right)^{1/(2(q+\alpha))}.$$

Trên đây, $q = \min\{(k-1), (d-1)\}$, α là một hằng số dương phụ thuộc vào γ , O_P có nghĩa là “hằng số cận trên trong xác suất”, được xác định đối với phân phối $p(\mathbf{x}|\theta)$.

Nếu số lượng văn bản càng tăng, thì suy diễn của ta càng chính xác!

- Chúng ta tạm dừng một chốc lát, để quay lại với thảo luận về sự cần thiết của mô hình xác suất $p(\mathbf{x}|\boldsymbol{\theta})$, một chất keo toán học kết nối dữ liệu quan sát được $\mathbf{x}$, với khái niệm “chân lý” ẩn sau đó, $\boldsymbol{\theta}$
- Các nhà thống kê đều đồng ý với nhau rằng dữ liệu phải được xem là hiện sinh của một biến ngẫu nhiên, do sự bất định của quan sát.
- Nhưng có một sự tranh cãi quyết liệt về ý nghĩa của khái niệm $\boldsymbol{\theta}$: nó có bất định hay không?
- Có hai trường phái đối với câu hỏi này: Các nhà *thống kê tần suất* cho rằng $\boldsymbol{\theta}$ hoàn toàn có thể xác định được. Phương pháp ước lượng cực đại của hàm khả dĩ (MLE) chính là một sản phẩm của các nhà tần suất.
- Ngược lại, trường phái *Bayes* cho rằng tri thức về $\boldsymbol{\theta}$ cũng bất định, và do đó về mặt toán học, nó cũng phải được biểu diễn bởi một biến ngẫu nhiên.
- Vì chúng ta không thể quan sát được khái niệm trừu tượng $\boldsymbol{\theta}$, chúng ta không thể xác quyết đúng sai trong tranh cãi này.

- Một ưu thế của phương pháp suy diễn Bayes là nó không chỉ cung cấp cho ta một điểm ước lượng cho θ , nó còn cho ta biết mức độ (không) chắc chắn của ước lượng đó, dựa trên những dữ liệu ta thu thập được.
- Để áp dụng phương pháp Bayes, tham số θ , bởi được xem là biến ngẫu nhiên, phải được gán cho một phân bố trước khi có dữ liệu.
 - ▶ Phân phối này được gọi là *phân bố tiên nghiệm*, ký hiệu bởi $\Pi(\theta)$, nó là chất lọc của tri thức mà nhà thống kê có được trước khi anh ta quan sát.
 - ▶ Sau khi đã thu thập dữ liệu, m văn bản $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}$, kiến thức của nhà thống kê về θ được tổng kết thành *phân bố hậu nghiệm*.
- Phân bố hậu nghiệm được xác định bằng công thức Bayes nổi tiếng:

$$d\Pi(\theta|\mathbf{x}) = \frac{p(\mathbf{x}|\theta) \cdot d\Pi(\theta)}{\int p(\mathbf{x}|\theta) \cdot d\Pi(\theta)}.$$

- Có thể chứng minh được rằng khi số lượng dữ liệu càng nhiều thì phân bố hậu nghiệm tập trung càng gần về giá trị “chân lý” của θ (Nguyen, 2015): niềm tin của các nhà thống kê Bayes cũng tiệm cận dần tới chân lý!

Thuật toán học chủ đề

- Thách thức cho Thống kê hiện đại và học máy: mục tiêu tính toán hiệu quả những đại lượng trọng yếu như ước lượng MLE, hay phân bố hậu nghiệm.
 - ▶ để có độ tin cậy cao các thuật toán phải quét qua một số lớn các văn bản có độ dài khác nhau, con số đó có thể đến hàng vạn, hàng triệu, thậm chí hàng tỷ
 - ▶ thời gian chạy thuật toán có thể mất hàng ngày hoặc hàng tuần để có được kết quả tương đối chính xác của bài toán tìm cực đại cho hàm khả dĩ.
- Thường chỉ cần tìm các giải pháp xấp xỉ
 - ▶ phép suy diễn biến phân (variational inference) (Blei et al, 2003).
 - ▶ phương pháp suy diễn Bayes xấp xỉ dựa vào Markov Chain Monte Carlo