

ƯỚC LƯỢNG THAM SỐ QUÁ TRÌNH TRAINING

$$data\ science = \int_{\Omega} data \cdot (math \wedge stat \wedge cs \wedge \dots)?$$

ƯỚC LƯỢNG ĐIỂM

- trong thời đại "big data", lắm cơ hội song cũng nhiều cạm bẫy
 - ▶ dữ liệu có thể đánh lừa
 - ▶ dữ liệu thu thập được dễ dàng cũng dễ làm ta lười đi: lười trong suy nghĩ, lười hót trong cách thức tổ chức và cầu thả trong phân tích
- trong các địa hạt nghiên cứu: dễ bị loá mắt bởi những phương pháp nóng và đang hợp thời thượng
 - ▶ để thành công bền vững, phải đi vào những vấn đề nền tảng
- Điều này có nghĩa: phải xây dựng trên nền tảng vững chắc của toán, thống kê, khoa học máy tính, nếu ta muốn phát triển KHDL một cách vững vàng

Prediction

Mọi phương pháp dự báo đều bắt đầu từ dữ liệu X để ước lượng Y


$$X \longrightarrow \boxed{METHOD} \longrightarrow Y$$

Ví dụ: dữ liệu X về dung lượng giao thông của các địa điểm
 Y là một giá trị nhị phân để dự báo đường có bị tắc hay không

Giả dụ: X và Y được liên hệ với nhau bởi một đại lượng chân lý nào đó kết nối X và Y , ta tạm gọi là θ

$$X \longleftrightarrow \theta \longleftrightarrow Y$$

Data, information, knowledge



Statistics vs. Machine Learning

Statistics

- Suy diễn thống kê (ước lượng, kiểm định giả thiết).
- Ban đầu mô hình cho bài toán có số chiều nhỏ, ở dạng số.
- Khó thay đổi 'văn hóa', thích nghi với môi trường tính toán.
- Mở rộng sang học máy.



Machine learning


- Dự đoán với dữ liệu hình thức.
- Bắt đầu với các thuật toán trực cảm (heuristics).
- Dần gần với thống kê, có mô hình toán học cho các thuật toán.




1. Khái niệm về ước lượng tham số

- Xét một tổng thể Ω và giả sử ta quan tâm tới biến lượng X đo lường về một dấu hiệu nào đó của cá thể trong tổng thể (doanh thu của doanh nghiệp vừa và nhỏ, tỉ lệ tiết kiệm của người dân thành phố). Các tổng thể ở đây là tập tất cả các doanh nghiệp vừa và nhỏ hay toàn bộ người dân sống ở thành phố, các biến lượng X ở đây có thể là doanh thu, tỉ lệ tiết kiệm.


Population



Samples



sample set 1



sample set 2

- Về mặt toán học X là một ĐLNN vì giá trị của nó thay đổi từ cá thể này đến cá thể khác. Do vậy ta cần phải biết phân bố của X tức là tập các giá trị có thể có của X cùng với các xác suất để nó nhận giá trị đó. Tuy nhiên phân bố của X rất khó nắm bắt cho nên ta thường quan tâm đến một số tham số đặc trưng của phân bố như: kì vọng, phương sai, mode, trung vị.... Việc xác định các tham số này từ dữ liệu quan sát được người ta gọi là quá trình ước lượng tham số.
- Giả sử $x_1, x_2, \dots, x_n$ là n giá trị quan sát được về ĐLNN X , từ các giá trị này ta cần thiết lập một biểu thức để làm ước lượng cho tham số mà ta chưa biết.

Định nghĩa 1. Một hàm $\hat{\theta} = T(x_1, x_2, \dots, x_n)$ của n giá trị $x_1, x_2, \dots, x_n$ được gọi là một ước lượng điểm cho tham số θ .

- $\mathbf{x}$ làm ký hiệu cho đầu vào của một thuật toán. I.e., $\mathbf{x}$ là biểu diễn của tập các văn bản
- θ là đầu ra thuật toán; nó là biểu diễn cho các chủ đề chúng ta muốn chất lọc từ nội dung của dữ liệu $\mathbf{x}$
- $\mathbf{x}$ lấy giá trị ở trong một không gian mà chúng ta sẽ định nghĩa một cách hình thức. Tương tự như vậy với θ

Để có thể suy diễn được chủ đề θ từ dữ liệu thô $\mathbf{x}$, chúng ta cần phải thiết lập được một sự liên hệ giữa θ và $\mathbf{x}$.

Mô hình xác suất $\mathbb{P}(\mathbf{x}|\theta)$

- dữ liệu được xem là hiện sinh (realization) của một biến ngẫu nhiên $\mathbf{x}$, còn chủ đề θ là một tham số cho phân phối của dữ liệu
- dùng ngôn ngữ xác suất để xác lập mô hình toán học cho dữ liệu được xem là hết sức tự nhiên, vì dữ liệu thường có yếu tố **bất định**:
 - ▶ mỗi lần thu thập dữ liệu mới ta thường nhận một giá trị khác nhau, cho dù quy luật sinh ra dữ liệu có thể được xác định bởi cùng một phân bố “chân lý”
 - ▶ dẫu ta không bao giờ biết chắc chắn được phân bố chân lý, bằng những hiểu biết từ dữ liệu thực tế chúng ta có thể tìm một lớp phân bố xấp xỉ khả dĩ cho phân bố chân lý
 - ▶ lớp phân bố ấy sẽ được tham số hoá bởi θ
- bằng dữ liệu thực, chúng ta sẽ tìm giá trị tốt nhất có thể cho θ

$$f(x, \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{\frac{-(x-\mu)^2}{2\sigma^2}}; \theta = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix}$$

- Các máy học thống kê (Machine Learning; Statistical Learning) đều làm nhiệm vụ chính là ước lượng tham số (quá trình học, training: huấn luyện).
- Sau khi ước lượng được tham số thì máy tính sẽ thiết lập các hàm mục tiêu (toán kinh tế) dựa trên các tham số học được.
- Sau đó tìm cực đại của hàm mục tiêu (phương trình Euler, điều khiển tối ưu, quy hoạch động) và đưa ra quyết định (quá trình quyết định Markov MDP, Reinforcement Learning...)

Định nghĩa 2. (Ước lượng không chệch)

Ước lượng $\hat{\theta}_n$ được gọi là ước lượng không chệch của θ nếu $E[\hat{\theta}_n] = \theta$.

Định nghĩa 3. (Ước lượng vững)

Ước lượng $\hat{\theta}_n$ được gọi là ước lượng vững của θ nếu

$$\lim_{n \rightarrow \infty} P\left[\left|\hat{\theta}_n - \theta\right| < \varepsilon\right] = 1 \text{ trong đó } \varepsilon > 0 \text{ nhỏ tùy ý.}$$

Định nghĩa 4. (Ước lượng hiệu quả)

Ước lượng $\hat{\theta}_n$ được gọi là ước lượng hiệu quả của θ nếu $\hat{\theta}_n$ là ước lượng không chệch và phương sai nhỏ nhất trong số các ước lượng không chệch.

- Nhận xét: Có vô số ước lượng không chệch của tham số do vậy để tìm ước lượng có phương sai nhỏ nhất là một điều khó. Để chứng minh một ước lượng cho tham số là ước lượng hiệu quả chúng ta cần sử dụng bất đẳng thức Cramer-Rao ở phần sau.

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$$

$$S^2 = \frac{\left(X_1 - \bar{X}\right)^2 + \left(X_2 - \bar{X}\right)^2 + \dots + \left(X_n - \bar{X}\right)^2}{n} = \frac{1}{n} \sum_{i=1}^n \left(X_i - \bar{X}\right)^2$$

$$\hat{S}^2 = \frac{(X_1 - \bar{X})^2 + (X_2 - \bar{X})^2 + \dots + (X_n - \bar{X})^2}{n-1} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n}{n-1} \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n}{n-1} S^2$$

Phương pháp hợp lý cực đại
(maximum likelihood estimator
:MLE)

Xét một biến ngẫu nhiên X với hàm mật độ $f(x, \theta)$ phụ thuộc vào tham số

(véc tơ tham số) θ chưa biết và ta muốn ước lượng θ thông qua các quan sát về X .

Ta lập một hàm gọi là hàm hợp lý dựa trên các quan sát về X và các giá trị khác nhau của θ . Ta chọn một giá trị $\hat{\theta}$ của θ sao cho hàm hợp lý này đạt giá trị lớn nhất (cực đại) thì ta khi đó $\hat{\theta}$ được dùng làm ước lượng cho θ .

$$\begin{aligned}
 P\left(X \in (x, x + dx)\right) &= \int_x^{x+dx} f(t, \theta) dt \approx \int_x^{x+dx} f(x, \theta) dt \\
 &= f(x, \theta) t \Big|_x^{x+dx} = f(x, \theta) dx
 \end{aligned}$$

Khi đó $f(x, \theta)$ sẽ đại diện cho xác suất để BNN X nhận giá trị trong một khoảng có độ dài dx không đổi. Nếu xác suất này lớn ta nói rằng X xuất hiện trong khoảng đó một cách hợp lý. Do vậy khi ta quan sát về X , ta sẽ tính được $f(x, \theta)$ khi $X=x$ và với giá trị cụ thể của θ . Ta chọn ước lượng của θ sao cho xác suất trên đây là cao nhất (hợp lý nhất) nghĩa là với thực tế cho trước ta cần chọn tham số θ sao cho xác suất của biến ngẫu nhiên nằm trong vùng thực tế đó là lớn nhất.

Định nghĩa 5. Ước lượng hợp lý cực đại

Giả sử $(X_1, X_2, \dots, X_n)$ là một mẫu ngẫu nhiên gồm các quan sát độc lập về X với hàm mật độ $f(x, \theta)$. Khi đó hàm số

$$f(X_1, X_2, \dots, X_n; \theta) = f(X_1, \theta) f(X_2, \theta) \dots f(X_n, \theta) = \prod_{i=1}^n f(X_i, \theta)$$

được gọi là hàm hợp lý của mẫu quan sát $(X_1, X_2, \dots, X_n)$.

Giá trị $\hat{\theta}$ làm cực đại hàm hợp lý được gọi là ước lượng hợp lý cực đại của θ :


$$f(X_1, X_2, \dots, X_n; \hat{\theta}) = \max_{\theta} f(X_1, X_2, \dots, X_n; \theta)$$

Biểu diễn cho mô hình sinh dữ liệu $\mathbb{P}(\mathbf{x}|\theta)$

$$\mathbb{P} \left(\mathbf{x} = \begin{array}{|l} \text{The William Randolph Hearst Foundation will give \$1.25 million to Lincoln Center, Metropolitan Opera Co., New York Philharmonic and Juilliard School. "Our board felt that we had a real opportunity to make a mark on the future of the performing arts with these grants an act every bit as important as our traditional areas of support in health, medical research, education and the social services," Hearst Foundation President Randolph A. Hearst said Monday in announcing the grants. Lincoln Center's share will be \$200,000 for its new building, which will house young artists and provide new public facilities. The Metropolitan Opera Co. and New York Philharmonic will receive \$400,000 each. The Juilliard School, where music and the performing arts are taught, will get \$250,000. The Hearst Foundation, a leading supporter of the Lincoln Center Consolidated Corporate Fund, will make its usual annual \$100,000 donation, too.} \end{array} \middle| \theta = \begin{array}{|l|l|l|l|} \hline \text{"Arts"} & \text{"Budgets"} & \text{"Children"} & \text{"Education"} \\ \hline \text{NEW} & \text{MILLION} & \text{CHILDREN} & \text{SCHOOL} \\ \text{FILM} & \text{TAX} & \text{WOMEN} & \text{STUDENTS} \\ \text{SHOW} & \text{PROGRAM} & \text{PEOPLE} & \text{SCHOOLS} \\ \text{MUSIC} & \text{BUDGET} & \text{CHILD} & \text{EDUCATION} \\ \text{MOVIE} & \text{BILLION} & \text{YEARS} & \text{TEACHERS} \\ \text{PLAY} & \text{FEDERAL} & \text{FAMILIES} & \text{HIGH} \\ \text{MEDICAL} & \text{YEAR} & \text{WORK} & \text{PUBLIC} \\ \text{BEST} & \text{SPENDING} & \text{PARENTS} & \text{TEACHER} \\ \text{ACTOR} & \text{NEW} & \text{SAYS} & \text{BENNETT} \\ \text{FIRST} & \text{STATE} & \text{FAMILY} & \text{MANHATT} \\ \text{YORK} & \text{PLAN} & \text{WELFARE} & \text{NAMPREV} \\ \text{OPERA} & \text{MONEY} & \text{MEN} & \text{STATE} \\ \text{THEATER} & \text{PROGRAMS} & \text{PERCENT} & \text{PRESIDENT} \\ \text{ACTRESS} & \text{GOVERNMENT} & \text{CARE} & \text{ELEMENTARY} \\ \text{LOVE} & \text{CONGRESS} & \text{LIFE} & \text{BAIT} \\ \hline \end{array} \right)$$

- Cho V là bộ từ điển gồm có d phần tử (từ vựng) được đánh số bằng $V = \{1, \dots, d\}$
 - ▶ với văn bản dài n từ, ta viết $\mathbf{x} = (x_1, \dots, x_n) \in V^n$.
- Giả sử rằng có k chủ đề ẩn khác nhau $\theta = (\theta_1, \dots, \theta_k)$, tương ứng với k phần tử nằm trong đơn hình xác suất

$$\Delta^{d-1} := \{u \in [0, 1]^d \mid u_1 + \dots + u_d = 1\}.$$



Mỗi chủ đề $\theta_i \in \Delta^{d-1}$ tương ứng với một tần suất xuất hiện nhất định của các từ trong V .

- Ví dụ: một chủ đề về “giáo dục” sẽ có nhiều từ với tần suất xuất hiện cao như “trường”, “lớp”, “học sinh”, “học phí”, v.v.
- Một chủ đề về “đảng” sẽ có những từ khác với tần suất cao, như “nghị quyết”, “quán triệt”, “tiến lên”, “to lớn”, v.v.

- Chúng ta không thể tìm ra chính xác các chủ đề θ , chỉ có thể ước lượng chúng.
- Nhưng ta kỳ vọng rằng nếu số lượng dữ liệu m, n càng lớn thì các ước lượng đối với θ càng tiến gần đến giá trị “chân lý” của chúng.
- Mặt khác, đây cũng không phải là vấn đề đơn giản về mặt tính toán, mà phải cần những hỗ trợ về thuật toán đủ mạnh
- Đó là các thuật toán “học máy” lấy đầu vào là tập m văn bản, và đầu ra chính là các ước lượng về “chủ đề”!

Ví dụ 2. Tìm ước lượng hợp lý cực đại cho các tham số của BNN có phân bố chuẩn

$$f(x, \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{\frac{-(x-\mu)^2}{2\sigma^2}}; \theta = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix}$$

$$f(X_1, X_2, \dots, X_n; \theta) = f(X_1, \theta) f(X_2, \theta) \dots f(X_n, \theta)$$

$$= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X_1 - \mu)^2}{2\sigma^2}} \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X_2 - \mu)^2}{2\sigma^2}} \dots \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X_n - \mu)^2}{2\sigma^2}}$$

$$= \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n \cdot e^{-\frac{(X_1 - \mu)^2}{2\sigma^2} - \frac{(X_2 - \mu)^2}{2\sigma^2} \dots - \frac{(X_n - \mu)^2}{2\sigma^2}}$$

$$L(X_1, X_2, \dots, X_n; \theta) = \ln \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n - \left[\frac{(X_1 - \mu)^2}{2\sigma^2} + \frac{(X_2 - \mu)^2}{2\sigma^2} + \dots + \frac{(X_n - \mu)^2}{2\sigma^2} \right]$$

$$\begin{cases} \frac{\partial L(X_1, X_2, \dots, X_n; \theta)}{\partial \mu} = 0 \\ \frac{\partial L(X_1, X_2, \dots, X_n; \theta)}{\partial y} = 0 \end{cases}$$

$$L = -\frac{n}{2} \ln(2\pi y) - \left[\frac{(X_1 - \mu)^2}{2y} + \frac{(X_2 - \mu)^2}{2y} + \dots + \frac{(X_n - \mu)^2}{2y} \right]$$

$$\begin{cases} -\left[\frac{2(X_1 - \mu)(-1)}{2y} + \frac{2(X_2 - \mu)(-1)}{2y} + \dots + \frac{2(X_n - \mu)(-1)}{2y} \right] = 0 \\ -\frac{n}{2} \frac{2\pi}{2\pi y} - \left[-\frac{(X_1 - \mu)^2}{2y^2} - \frac{(X_2 - \mu)^2}{2y^2} - \dots - \frac{(X_n - \mu)^2}{2y^2} \right] = 0 \end{cases}$$

$$\begin{cases} \frac{(X_1 - \mu)}{y} + \frac{(X_2 - \mu)}{y} + \dots + \frac{(X_n - \mu)}{y} = 0 \\ -n + \left[\frac{(X_1 - \mu)^2}{y} + \frac{(X_2 - \mu)^2}{y} + \dots + \frac{(X_n - \mu)^2}{y} \right] = 0 \end{cases}$$

$$\Leftrightarrow \begin{cases} X_1 + X_2 + \dots + X_n = n\mu \\ y = \frac{1}{n} \left[(X_1 - \mu)^2 + (X_2 - \mu)^2 + \dots + (X_n - \mu)^2 \right] \end{cases}$$

$$\Leftrightarrow \begin{cases} \hat{\mu} = \frac{X_1 + X_2 + \dots + X_n}{n} \\ \hat{\sigma}^2 = \frac{1}{n} \left[(X_1 - \hat{\mu})^2 + (X_2 - \hat{\mu})^2 + \dots + (X_n - \hat{\mu})^2 \right] \end{cases}$$

$$\Leftrightarrow \begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = S^2 \end{cases}$$

Ví dụ 3. Ước lượng các tham số của phân bố Gamma bằng phương pháp ML. Cho biết hàm mật độ của phân bố Gamma có dạng

$$f(x|\alpha,\lambda) = \frac{1}{\Gamma(\alpha)} \lambda^\alpha x^{\alpha-1} e^{-\lambda x}$$

$$\Gamma(\alpha) = \int_0^{\infty} e^{-t} t^{\alpha-1} dt$$

$$\begin{aligned}
 f(X_1, X_2, \dots, X_n; \theta) &= \frac{1}{\Gamma(\alpha)} \lambda^\alpha X_1^{\alpha-1} e^{-\lambda X_1} \frac{1}{\Gamma(\alpha)} \lambda^\alpha X_2^{\alpha-1} e^{-\lambda X_2} \dots \frac{1}{\Gamma(\alpha)} \lambda^\alpha X_n^{\alpha-1} e^{-\lambda X_n} \\
 &= \prod_{i=1}^n \frac{1}{\Gamma(\alpha)} \lambda^\alpha X_i^{\alpha-1} e^{-\lambda X_i}
 \end{aligned}$$

$$L(X_1, X_2, \dots, X_n; \theta) = \ln \prod_{i=1}^n \frac{1}{\Gamma(\alpha)} \lambda^\alpha X_i^{\alpha-1} e^{-\lambda X_i} = -n \ln \Gamma(\alpha) + n\alpha \ln \lambda + (\alpha - 1) \sum_{i=1}^n \ln X_i - \lambda \sum_{i=1}^n X_i$$

$$\begin{cases} \frac{\partial L}{\partial \lambda} = 0 \\ \frac{\partial L}{\partial \alpha} = 0 \end{cases} \Leftrightarrow \begin{cases} \frac{n\alpha}{\lambda} - \sum_{i=1}^n X_i = 0 \\ \frac{-n\Gamma'(\alpha)}{\Gamma(\alpha)} + n \ln \lambda + \sum_{i=1}^n \ln X_i = 0 \end{cases} \Leftrightarrow \begin{cases} \lambda = \frac{n\alpha}{\sum_{i=1}^n X_i} = \frac{\alpha}{\bar{X}} \\ \frac{-n\Gamma'(\alpha)}{\Gamma(\alpha)} + n \ln \frac{\alpha}{\bar{X}} + \sum_{i=1}^n \ln X_i = 0 \end{cases} \quad (1)$$

$$\frac{-n\Gamma'(\alpha)}{\Gamma(\alpha)} + n \ln \frac{\alpha}{\bar{X}} + \sum_{i=1}^n \ln X_i = 0 \quad (2)$$

**Ước lượng hợp lý cực đại cho
ĐLNN có phân bố rời rạc**

Xét 1 ĐLNN X có phân bố rời rạc như sau

X	x₁	x₂	...	x_m
P	p₁	p₂	<u>.....</u>	p_m

Cho biết dữ liệu về ĐLNN X , $(X_1, X_2, \dots, X_m)$ trong đó X_i là số lần quan sát được giá trị x_i . Giả sử ta có tổng số n quan sát khi đó

$$X_1 + X_2 + \dots + X_m = n$$

Lập hàm hợp lý cho dữ liệu như sau:

$$f(X_1, X_2, \dots, X_m) = p_1^{X_1} p_2^{X_2} \dots p_m^{X_m} \Rightarrow L = X_1 \ln p_1 + X_2 \ln p_2 + \dots + X_m \ln p_m$$

ta cần cực đại của loga hàm hợp lý với ràng buộc

$$p_1 + p_2 + \dots + p_m = 1.$$

$$Lg = X_1 \ln p_1 + X_2 \ln p_2 + \dots + X_m \ln p_m + \lambda (p_1 + p_2 + \dots + p_m - 1)$$

$$\begin{cases} \frac{\partial Lg}{\partial p_1} = 0 \\ \vdots \\ \frac{\partial Lg}{\partial p_m} = 0 \\ \frac{\partial Lg}{\partial \lambda} = 0 \end{cases} \Leftrightarrow \begin{cases} \frac{X_1}{p_1} + \lambda = 0 \\ \vdots \\ \frac{X_m}{p_m} + \lambda = 0 \\ p_1 + p_2 + \dots + p_m - 1 = 0 \end{cases} \Leftrightarrow \begin{cases} p_1 = \frac{-X_1}{\lambda} \\ \vdots \\ p_m = \frac{-X_m}{\lambda} \\ -\frac{X_1}{\lambda} - \dots - \frac{X_m}{\lambda} = 1 \end{cases} \Leftrightarrow \begin{cases} p_1 = \frac{-X_1}{\lambda} \\ \vdots \\ p_m = \frac{-X_m}{\lambda} \\ \lambda = -n \end{cases} \begin{cases} p_1 = \frac{X_1}{n} \\ \vdots \\ p_m = \frac{X_m}{n} \\ \lambda = -n \end{cases}$$

50 years of Data Science

David Donoho

Sept. 18, 2015

Version 1.00

Abstract

’s ago, John Tukey called for a reformation of acaden
’sis’, he pointed to the existence of an as-yet unrecog
as learning from data, or ‘data analysis’. Ten to two
land and Leo Breiman independently once again urge
ries beyond the classical domain of theoretical statist
i data preparation and presentation rather than stat
phasis on prediction rather than inference. Clevelan
cience” for his envisioned field.

Statistical Modeling: The Two Cultures

Leo Breiman

Abstract: There are two cultures in the use of statistical modeling to reach conclusions from data. One assumes that the data are generated by a given stochastic data model. The other uses algorithmic models and treats the data mechanism as unknown. The statistical community has been committed to the almost exclusive use of data models. This commitment has led to treatment theory, questionable conclusions, and has kept statisticians from working on a large range of interesting current problems. Algorithmic modeling, both in theory and practice, has developed rapidly in fields outside statistics. It can be used both on large complex data sets and on a more accurate and informative alternative to data modeling on smaller data sets. If our goal is to use data to solve problems, then we need to move away from exclusive dependence on data models and adopt a more diverse set of tools.

$$\max_{\theta} \mathbb{P} \left(\mathbf{x} = \right.$$

The **Billie Jean King Award** Foundation will give \$1.25 million to **Lincoln Center**, Metropolitan Opera Co., New York Philharmonic, and **Lincoln School**. “Our **largest** idea that we had a **real opportunity** to make a mark on the future of the performing arts with these **grants** as an **every bit as important** as our traditional areas of support in health, medical research, education and the social services.” **Lincoln Foundation President Randolph A. Harms** said Monday in announcing the **grants**. **Lincoln Center’s** share will be \$200,000 for its new **building**, which will house young artists and provide **arts** **public** **education**. The Metropolitan Opera Co. and New York Philharmonic will receive \$400,000 each. The **Lincoln School**, where music and the performing arts are taught, will get \$250,000. The **Harms Foundation**, a leading supporter of the **Lincoln Center** Consolidated Corporate **Trust**, will make its usual **annual** \$100,000 donation, too.

So we obtain

$\theta =$

“Arts”	“Budgets”	“Children”	“Education”
NEW	MILLION	CHILDREN	SCHOOL
FILM	TAX	WOMEN	STUDENTS
SHOW	PROGRAM	PEOPLE	SCHOOLS
MUSIC	BUDGET	CHILD	EDUCATION
MOVIE	BILLION	YEARS	TEACHERS
PLAY	FEDERAL	FAMILIES	HIGH
MUSICAL	YEAR	WORK	PUBLIC
BEST	SPENDING	PARENTS	TEACHER
ACTOR	NEW	SAYS	BENNETT
FIRST	STATE	FAMILY	MANIGAT
YORK	PLAN	WELFARE	NAMPHY
OPERA	MONEY	MEN	STATE
THEATER	PROGRAMS	PERCENT	PRESIDENT
ACTRESS	GOVERNMENT	CARE	ELEMENTARY
LOVE	CONGRESS	LIFE	HAITI

Cách tiếp cận Bayes trong ước lượng tham số

- Chúng ta tạm dừng một chốc lát, để quay lại với thảo luận về sự cần thiết của mô hình xác suất $p(\mathbf{x}|\theta)$, một chất keo toán học kết nối dữ liệu quan sát được $\mathbf{x}$, với khái niệm “chân lý” ẩn sau đó, θ

- Các nhà thống kê đều đồng ý với nhau rằng dữ liệu phải được xem là hiện sinh của một biến ngẫu nhiên, do sự bất định của quan sát.

- Nhưng có một sự tranh cãi quyết liệt về ý nghĩa của khái niệm θ : nó có bất định hay không?

- Có hai trường phái đối với câu hỏi này: Các nhà *thống kê tần suất* cho rằng θ hoàn toàn có thể xác định được. Phương pháp ước lượng cực đại của hàm khả dĩ (MLE) chính là một sản phẩm của các nhà tần suất.

- Ngược lại, trường phái *Bayes* cho rằng tri thức về θ cũng bất định, và do đó về mặt toán học, nó cũng phải được biểu diễn bởi một biến ngẫu nhiên.
- Vì chúng ta không thể quan sát được khái niệm trừu tượng θ , chúng ta không thể xác quyết đúng sai trong tranh cãi này.

- Một ưu thế của phương pháp suy diễn Bayes là nó không chỉ cung cấp cho ta một điểm ước lượng cho θ , nó còn cho ta biết mức độ (không) chắc chắn của ước lượng đó, dựa trên những dữ liệu ta thu thập được.
- Để áp dụng phương pháp Bayes, tham số θ , bởi được xem là biến ngẫu nhiên, phải được gán cho một phân bố trước khi có dữ liệu.
 - ▶ Phân phối này được gọi là *phân bố tiên nghiệm*, ký hiệu bởi $\Pi(\theta)$, nó là chất lọc của tri thức mà nhà thống kê có được trước khi anh ta quan sát.
 - ▶ Sau khi đã thu thập dữ liệu, m văn bản $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}$, kiến thức của nhà thống kê về θ được tổng kết thành *phân bố hậu nghiệm*.

- Phân bố hậu nghiệm được xác định bằng công thức Bayes nổi tiếng:

$$d\Pi(\theta|\mathbf{x}) = \frac{p(\mathbf{x}|\theta) \cdot d\Pi(\theta)}{\int p(\mathbf{x}|\theta) \cdot d\Pi(\theta)}.$$

- Có thể chứng minh được rằng khi số lượng dữ liệu càng nhiều thì phân bố hậu nghiệm tập trung càng gần về giá trị “chân lý” của θ (Nguyen, 2015): niềm tin của các nhà thống kê Bayes cũng tiệm cận dần tới chân lý!

Mẫu số của phân bố hậu nghiệm chỉ phụ thuộc vào dữ liệu không phụ thuộc vào θ , còn tử số là tích của hàm hợp lý và hàm mật độ tiên nghiệm của tham số cho nên ta có thể viết:

Mật độ hậu nghiệm $\propto$ Hàm hợp lý $\times$ hàm mật độ tiên nghiệm.

Trong ước lượng Bayes ta cũng tìm cực đại của hàm mật độ hậu nghiệm và có khác so với phương pháp hợp lý cực đại là hàm mật độ hậu nghiệm xuất hiện thêm nhân tử là mật độ tiên nghiệm. Khi mật độ tiên nghiệm là phân bố đều thì ước lượng Bayes trùng với ước lượng MLE.

Tổng thể và mẫu

- Khoảng tin cậy mô tả lượng không chắc chắn liên quan đến ước lượng mẫu của một tham số tổng thể. Người ta cần hiểu rõ về sự khác biệt giữa các mẫu và tổng thể để hiểu sự cần thiết của việc cung cấp các ước tính thống kê trong một khoảng, hay còn gọi là khoảng tin cậy.



ƯỚC LƯỢNG KHOẢNG

- Khoảng tin cậy cho bạn biết mức độ tin cậy của bạn rằng kết quả từ một cuộc thăm dò hoặc khảo sát phản ánh những gì bạn mong đợi sẽ tìm thấy nếu có thể khảo sát toàn bộ tổng thể.
- Rất khó để có được dữ liệu đo lường của toàn bộ tập dữ liệu (tổng thể) do nguồn lực và thời gian có hạn.
- Cách tốt nhất của bạn là khảo sát một phần nhỏ (mẫu) của toàn bộ tập dữ liệu và cầu nguyện rằng dữ liệu mẫu của bạn đại diện cho dân số một cách hợp lý

- Dữ liệu mẫu có thể không phải là một đại diện tốt của một tập hợp theo nhiều yếu tố (Ví dụ: độ chệch), và kết quả là, độ không chắc chắn luôn được đưa ra trong bất kỳ ước tính nào bắt nguồn từ dữ liệu mẫu.
- Do sự không chắc chắn liên quan đến dữ liệu mẫu, bất kỳ ước tính thống kê nào cần được phân phối trong một phạm vi, không phải trong một ước tính điểm.
- Ước lượng của một tham số tổng thể tốt như thế nào luôn là một vấn đề.

- Khoảng tin cậy giải quyết vấn đề này bằng cách cung cấp một phạm vi giá trị, có khả năng chứa tham số tổng thể quan tâm trong phạm vi độ tin cậy cho trước.

100% chance that your clip length
falls between 2cm and 3cm



depends on tick mark spacing

point estimate $\pm$ measurement E.
 2.5 ± 0.5 cm

- Dựa trên hình (1), chiếc kẹp giấy có vẻ dài khoảng 2,7 cm, nhưng chúng ta không biết chắc chắn vì các dấu tích trên thước không đủ chính xác để đo độ dài phần thập phân.
- Tuy nhiên, tôi có thể chắc chắn 100% rằng chiếc kẹp giấy có chiều dài từ 2 ~ 3 cm, vì chiếc kẹp nằm trong khoảng từ 2 cm đến 3 cm.
- Bạn ghi lại chiều dài của kẹp giấy trong một phạm vi, thay vì ước lượng điểm, để tính đến độ không đảm bảo do giới hạn của công cụ đo.

- Ý tưởng tương tự có thể được áp dụng cho khoảng tin cậy của giá trị trung bình. Bạn muốn lấy giá trị trung bình của toàn bộ tập dữ liệu (tập hợp), nhưng bạn có thể đo lường các giá trị chỉ của một phần nhỏ (mẫu) của toàn bộ tập dữ liệu.
- Điều này xoay quanh vấn đề truyền thống về Tổng thể so với Mẫu, do chi phí thu thập dữ liệu đo lường của một tập dữ liệu lớn.

- Sự không chắc chắn được đưa vào trong các mẫu của bạn, bởi vì bạn không biết liệu các mẫu của mình có đại diện 100% cho dân số hay không, không có sai lệch. Do đó, bạn đưa ra kết luận của mình trong một phạm vi, không phải trong một ước lượng điểm, để giải thích cho sự không chắc chắn.

- **Ví dụ 1: Sự không chắc chắn về độ xốp của đá**

- (Thống kê địa lý)



- Một kỹ sư vỉa trong ngành dầu khí muốn biết độ xốp của đá của một hệ tầng để ước tính tổng trữ lượng dầu 9.500 ft dưới lòng đất. Do chi phí cao để lấy các mẫu lõi đá từ các tầng sâu, ông chỉ có thể lấy được 12 mẫu lõi đá. Anh ta thu được độ xốp trung bình của đá là 14.5% với độ lệch chuẩn là 4.3%.

- Các nhà điều hành trong công ty muốn biết tình huống xấu nhất (P10) và tình huống tốt nhất (P90) để đưa ra quyết định kinh doanh.
- Bạn có thể truyền đạt ước tính của mình về độ xấp trung bình với độ không đảm bảo bằng cách xây dựng khoảng tin cậy của giá trị trung bình.
- Giả sử rằng bạn có lý do để tin rằng độ rộng của đá tuân theo phân phối chuẩn, bạn có thể xây dựng khoảng tin cậy 80% của nó, với quy trình được mô tả dưới đây:

- `import scipy.stats as st`
- `import numpy as np`
- `st.t.interval(1 - 0.2, 12 - 1, loc=14.5, scale= 4.3 / np.sqrt(12))`

`(12.807569748569543, 16.19243025143046)`

- Trong trường hợp xấu nhất, đá ở độ sâu 9.500 ft dưới lòng đất có độ rỗng 12,8%. Trong trường hợp tốt nhất, bể chứa dầu có độ rỗng 16,2%. Các quy trình tương tự có thể được áp dụng cho các mẫu lõi được thu thập ở các độ sâu khác nhau, cho chúng ta biểu đồ khoảng tin cậy của độ xốp của đá được thể hiện trong hình (2).



- **Ví dụ 2:**

- 21 mẻ pha lê do ông White nấu cho thấy độ tinh khiết trung bình là 99,1% với độ lệch chuẩn 3%.
- 18 mẻ pha lê do ông Pinkman nấu cho thấy độ tinh khiết trung bình 96,2% với độ lệch chuẩn 4%.

- Có phải ông White luôn nấu tinh thể tốt hơn ông Pinkman, hay ông Pinkman có thể đánh bại ông White về độ tinh khiết của tinh thể nấu chín do may mắn hay không?
-

- Khoảng tin cậy 95%:


- # Mr. White's

```
stats.t.interval(1 - 0.05, 21 - 1, loc=99.1, scale= 3 / np.sqrt(21))  
(97.73441637228476, 100.46558362771523)
```

- # Mr. Pinkman's

```
stats.t.interval(1 - 0.05, 18 - 1, loc=96.2, scale= 4 / np.sqrt(18))
```

```
(94.21084679714819, 98.18915320285181)
```



- Có một sự trùng lặp nhỏ giữa khoảng tin cậy của ông White và ông Pinkman. Mặc dù đúng là ông White là người nấu bếp tốt hơn, nhưng ông Pinkman có thể nấu một mẻ tinh thể tinh khiết hơn nếu ông ấy có may mắn với một cơ hội nhỏ (Xác suất nhỏ).
- So sánh giá trị trung bình của hai tập dữ liệu mẫu có liên quan chặt chẽ đến việc xây dựng khoảng tin cậy của sự khác biệt về giá trị trung bình.

- **Ví dụ 3: Sự không chắc chắn trong dự báo sản lượng dầu**

- Một kỹ sư sản xuất trong ngành dầu khí muốn biết trường hợp xấu nhất (P10) và trường hợp tốt nhất (P90) trong dự báo sản lượng hydrocacbon.


- Trong kỹ thuật dầu khí, người ta sử dụng một kỹ thuật được gọi là Phân tích đường cong suy giảm (DCA) để dự đoán sản xuất hydrocacbon trong tương lai.
- Điều quan trọng là phải định lượng độ không chắc chắn của mô hình DCA của bạn, vì độ không chắc chắn trong sản xuất dầu có thể lớn tới hàng triệu đô la; giám đốc điều hành trong một công ty đưa ra các quyết định kinh doanh dựa trên các giá trị P10 và P90.

- Chủ yếu có ba mô hình cho DCA: hàm mũ, hypebol và điều hòa. Xét mô hình hypebol:

$$q = \frac{q_i}{(1 + bD_i t)^{1/b}}$$

- Đây là một bài toán hồi quy phi tuyến tính với ba tham số để tối ưu hóa: D_i , q_i và b . Biến độc lập là thời gian t . Chúng ta có thể xây dựng khoảng tin cậy của mô hình hồi quy để nhận các giá trị $P10$ và $P90$. Vì giải pháp phân tích cho khoảng tin cậy của mô hình phi tuyến tính phức tạp và dữ liệu không có phân phối chuẩn, chúng ta sử dụng phương pháp phi tham số, bootstrap, để thu được mô hình dự báo độ không chắc chắn sau:

Uncertainty in decline curve analysis with Bootstrap




3. Formula for confidence interval varies with statistics


For [confidence interval of mean](#)

$$\text{C.I.}_{\text{mean}} : \mu \pm \left(t_{\frac{\alpha}{2}, df} \times \frac{s}{\sqrt{n}} \right)$$

For [confidence interval of difference in mean](#)

$$\text{C.I.}_{\Delta \text{mean}} : (\mu_1 - \mu_2) \pm \left(t_{1-\frac{\alpha}{2}, df} \times \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \right)$$





For confidence interval of proportion

$$\text{C.I.}_{\text{proportion}} : \hat{p} \pm (t_{\frac{\alpha}{2}, df} \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}})$$

For [confidence interval of variance](#)

$$\text{C.I.}_{\text{variance}} : \frac{(n-1)s^2}{\chi^2_{\frac{\alpha}{2}}} \leq \sigma^2 \leq \frac{(n-1)s^2}{\chi^2_{1-\frac{\alpha}{2}}}$$

For confidence interval of standard deviation

$$\text{C.I.}_{\text{standard deviation}} : \sqrt{\frac{(n-1)s^2}{\chi^2_{\frac{\alpha}{2}}}} \leq \sigma \leq \sqrt{\frac{(n-1)s^2}{\chi^2_{1-\frac{\alpha}{2}}}}$$


- Các phương trình được liệt kê ở trên không hợp lệ nếu tập dữ liệu mẫu không được phân CHUẨN.
- Trong trường hợp dữ liệu không được phân phối CHUẨN, khoảng tin cậy của nó có thể được thay thế bằng các phương pháp phi tham số như bootstrapping hoặc thay vào đó sử dụng khoảng tin cậy là khoảng tin cậy tương đương Bayesian.
- Hoặc bạn có thể chuyển đổi dữ liệu của mình thành phân phối chuẩn bằng cách sử dụng phép chuyển đổi Box-Cox.

- Có nghĩa là với khả năng 95% ước lượng của thống kê nằm trong khoảng tin cậy



Luôn sử dụng phân vị t thay vì phân vị z

- Điều này là do phân phối t chiếm độ không chắc chắn trong mẫu lớn hơn phân phối chuẩn khi kích thước mẫu là nhỏ, nhưng hội tụ về phân phối chuẩn khi kích thước mẫu lớn hơn 30.


Phân bố Student với các bậc tự do khác nhau so sánh với phân bố chuẩn tắc




- 4. Khoảng tin cậy của phân phối chuẩn
- Tính toán khoảng tin cậy của một thống kê phụ thuộc vào hai yếu tố: loại thống kê và loại phân phối mẫu. Như đã giải thích ở trên, các công thức khác nhau tồn tại cho các loại thống kê khác nhau (Ví dụ: trung bình, std, phương sai) và các phương pháp khác nhau (Ví dụ: tăng cường, khoảng tin cậy, biến đổi Box-Cox) được sử dụng cho tập dữ liệu không bình thường. Chúng tôi sẽ đề cập đến khoảng tin cậy của giá trị trung bình, sự khác biệt về giá trị trung bình và phương sai.
- 4.1. Khoảng tin cậy của giá trị trung bình
- Khoảng tin cậy của giá trị trung bình được sử dụng để ước tính giá trị trung bình của tổng thể từ dữ liệu mẫu và định lượng độ không đảm bảo đo liên quan. Hãy xem xét hình sau:



Similar “enough”



“Significantly” different



Kết luận: $data\ science \geq \int_{\Omega} data \cdot (math \wedge stat \wedge cs)$

- Công nghệ thông tin mang cho ta nguồn dữ liệu dồi dào, làm nảy sinh một nhu cầu cần suy diễn với những dữ liệu ấy.

- Thống kê và toán học cho ta một nền móng và công cụ để suy diễn một cách hợp lý.
 - ▶ Ngược lại sự phát triển của khoa học suy diễn từ dữ liệu, dữ liệu lớn, cũng đưa toán học tới gần với các ứng dụng của xã hội hiện đại hơn bao giờ hết. Vấn đề suy diễn với các cấu trúc phức tạp cũng có tác dụng thúc đẩy sự phát triển nội tại của toán học.

- Không chỉ đòi hỏi sự chuẩn bị tốt về toán học, một chuyên gia về KHDL phải có sự tò mò đối với thực tiễn, có khả năng diễn đạt thành thực bằng ngôn ngữ của toán, có sự linh để sử dụng ngôn ngữ ấy vào dữ liệu thực.